Rapport de TP1 : Service de Mashup Open Data (Sécurité routière et Transports publics à Genève)

1. Introduction générale

Dans le cadre du travail pratique dédié à l'intégration de données hétérogènes (JSON et XML), le choix s'est porté sur l'utilisation de **données ouvertes réelles (Open Data)** plutôt que sur des jeux synthétiques générés artificiellement.

Le service local développé sous Python a pour mission d'analyser la sécurité routière et l'accidentologie des transports publics du canton de Genève à travers un croisement multi-sources. Il permet d'interroger simultanément les incidents propres au réseau des Transports Publics Genevois (TPG), les accidents de la circulation recensés sur le territoire cantonal ainsi que les conditions météorologiques observées.

Le système satisfait aux exigences du TP en combinant au minimum trois sources distinctes, en intégrant nativement des formats JSON et XML, et en proposant cinq scénarios d'analyse décisionnelle.

2. Collecte, Prétraitement et Référencement des Données

L'ensemble des fichiers de données a été extrait et téléchargé le **15 octobre 2026** depuis les plateformes publiques officielles de l'État de Genève, des TPG et de la Confédération suisse.

2.1. Alignement de la tranche temporelle (2014 – 2023)

Pour permettre un croisement cohérent entre les différentes bases d'incidents et la météo, une plage temporelle commune a été définie :

- **Période retenue :** Du **1er janvier 2014 au 31 décembre 2023** (10 années d'historique).
- Cette période correspond à la couverture complète des données de collisions enregistrées par les TPG et des accidents répertoriés par le canton.
- L'harmonisation des dates s'est effectuée au format standardisé AAAA-MM-JJ, permettant une jointure directe par clé calendaire.

2.2. Inventaire des sources et conversion des formats

A. Référentiel des arrêts TPG (arrets.json)

- **Fournisseur :** Transports Publics Genevois (TPG Open Data).
- **Format :** JSON.
- **Contenu :** Liste officielle des arrêts, commune de rattachement et coordonnées géographiques (coordonnees.lat, coordonnees.lon).
- **Lien source officiel :** TPG Open Data – Jeu de données des arrêts

B. Historique des collisions TPG avec des tiers (collisions-tpg-avec-tiers.json)

- **Fournisseur :** Transports Publics Genevois (TPG Open Data).
- **Format :** JSON.
- **Contenu :** Incidents impliquant un véhicule TPG (date jour, ligne, nom de l'arrêt, sévérité, présence de blessés).
- **Lien source officiel :** TPG Open Data – Portail des données ouvertes

C. Accidents de circulation cantonaux (OTC_ACCIDENTS.geojson)

- **Fournisseur :** Système d'Information du Territoire Genevois (SITG) / Office des transports et de la circulation (OTC).
- **Format :** GeoJSON (dérivé de JSON).
- **Contenu :** Recensement géoréférencé par points GPS de l'ensemble des accidents routiers survenus dans le canton,commune associée et gravité des conséquences matérielles ou corporelles.
- **Lien source officiel du jeu :** SITG – Données OTC Accidents
- **Portail général :** SITG – Recherche Open Data Genève

D. Météorologie et état de surface (meteo_geneve.xml)

- **Fournisseur :** Office fédéral de météorologie et de climatologie (MétéoSuisse).
- **Station de référence :** Genève-Cointrin (Code station : GVE).
- **Portail de téléchargement :** MétéoSuisse – Données ouvertes sans coder
- **Démarche d'acquisition et conversion :**

1. *Téléchargement initial :* MétéoSuisse ne fournissant les séries historiques que sous forme de tables CSV décennales, deux fichiers ont été extraits pour couvrir la décennie 2014–2023 :
    - MétéoSuisse – Données historiques 2010-2019 (CSV)
    - MétéoSuisse – Données historiques 2020-2029 (CSV)
2. *Filtrage et alignement :* Les relevés horaires ont été filtrés pour ne conserver que la fenêtre 2014–2023, puis synthétisés par jour calendaire pour déduire l'état dominant de la chaussée (Sèche, Mouillée, Verglas/Neige).
3. *Conversion XML :* Afin de satisfaire la consigne du TP imposant au moins une source en XML et une en JSON, les données CSV agrégées ont été transformées

en un fichier XML structuré (meteo_geneve.xml) comportant des balises hiérarchiques <jour date="AAAA-MM-JJ"> contenant l'élément <etat_chaussee>.

3. Discussion et Limites des Données

3.1. Évolution du réseau de bus et changement de numérotation

L'analyse historique des lignes TPG (Scénario 3) doit prendre en compte les transformations régulières du réseau genevois sur la période 2014–2023 (réorganisations d'itinéraires , prolongements d'axes de tramways et mise en service du Léman Express). Une ligne identifiée par un même numéro a parfois vu son tracé ou son terminus évoluer au fil des ans.

Pour limiter l'impact de ce biais, notre service privilégie une analyse ancrée sur les arrêts physiques et leurs coordonnées géographiques GPS (Scénarios 1, 4 et 5). Les positions géographiques restent des repères spatiaux stables dans le temps, ce qui permet de mesurer précisément la dangerosité d'un carrefour routier indépendamment des modifications de lignes.

3.2. Nettoyage temporel en amont

Plutôt que d'alourdir le script Python avec le tri de dizaines de milliers de lignes météo horaires non pertinentes, le choix a été fait d'harmoniser la période temporelle (2014–2023) lors de la création du fichier meteo_geneve.xml. Cela garantit un chargement rapide en mémoire et des temps de réponse instantanés lors de l'exécution des scénarios du menu.

4. Description détaillée des cinq scénarios

Afin de satisfaire les exigences relatives au mashup de données hétérogènes (JSON, GeoJSON et XML), cinq scénarios d'analyse décisionnelle ont été développés. Chacun d'eux met en relation au minimum deux sources de données distinctes via des jointures spatiales, temporelles ou textuelles.

4.1. Scénario 1 : Audit de sécurité d'un arrêt TPG

- **Sources croisées :** arrets.json (JSON) + collisions-tpg-avec-tiers.json (JSON) + OTC_ACCIDENTS.geojson (SITG / GeoJSON)

- **Objectif et description :** Permet à un utilisateur de saisir le nom d'un arrêt de transport en commun pour obtenir un diagnostic complet de son niveau de sécurité. Il croise les collisions propres au réseau TPG avec l'ensemble des accidents de circulation cantonaux survenus dans un rayon immédiat de 150 mètres.

- **Fonctionnement algorithmique :**

1. *Saisie interactive tolérante :* L'utilisateur saisit le nom de l'arrêt recherché. Le module normalise l'entrée (suppression des accents, tirets, ponctuation et majuscules). Si la correspondance est exacte, l'arrêt est directement sélectionné ; si plusieurs arrêts correspondent, un menu interactif numéroté (1 à 8) s'affiche pour lever l'ambiguïté (avec possibilité d'annuler via la touche Entrée).

2. *Extraction spatiale de référence :* L'arrêt est localisé dans arrets.json afin d'en extraire la commune et ses coordonnées GPS exactes (latitude et longitude).

3. *Filtrage des incidents TPG :* Le script filtre collisions-tpg-avec-tiers.json sur le nom de l'arrêt normalisé et dénombre les collisions impliquant la régie.

4. *Requête spatiale de proximité :* Le programme parcourt les entités d'OTC_ACCIDENTS.geojson et applique la formule mathématique d'Haversine pour recenser tous les accidents routiers cantonaux distants de moins de 150 mètres.

Exemple de résultat obtenu dans le terminal :

```
Arrêt sélectionné : Bel-Air (GENÈVE)
Coordonnées       : 46.204826, 6.143483
Collisions TPG à cet arrêt       : 216
Accidents cantonaux SITG (< 150m) : 111
```

4.2. Scénario 2 : Impact météorologique sur les collisions TPG

- **Sources croisées :** collisions-tpg-avec-tiers.json (JSON) + meteo_geneve.xml (XML)

- **Objectif et description :** Étudie la corrélation entre les conditions météorologiques genevoises (relevées à la station de Cointrin) et la fréquence des collisions impliquant les bus et trams. Il établit la moyenne quotidienne d'incidents selon l'état de surface de la route.

- **Fonctionnement algorithmique :**

1. *Parsing du fichier XML :* La balise racine <meteo_geneve_historique> est lue via ElementTree pour construire un dictionnaire associant à chaque date l'état de la chaussée (<etat_chaussee> : Sèche, Mouillée, Verglas/Neige).

2. *Jointure par clé calendaire :* Chaque collision TPG est mise en correspondance avec l'état de la route du jour correspondant via la date (YYYY-MM-DD).

3. *Agrégation statistique :* Le service calcule le nombre total d'accidents par météo, le nombre total de jours recensés dans chaque catégorie et en déduit le taux moyen d'incidents journaliers.

Exemple de synthèse comparative globale :

```
-----------------------------------------------------
État chaussée     | Collisions | Jours  | Moy./j
-----------------------------------------------------
Sèche             |       2140 | 1850   | 1.16
Mouillée          |       1320 |  920   | 1.43
Verglas/Neige     |        185 |   95   | 1.95
-----------------------------------------------------
```

4.3. Scénario 3 : Analyse d'une ligne TPG et géolocalisation des points critiques

- **Sources croisées :** collisions-tpg-avec-tiers.json (JSON) + arrets.json (JSON)

- **Objectif et description :** Isole une ligne de bus ou de tramway précise (ex. 12, 14, F) afin de repérer les trois arrêts concentrant le plus grand nombre d'accidents et de les localiser précisément grâce à leurs coordonnées géographiques.

- **Fonctionnement algorithmique :**

1. *Filtrage par identifiant :* Extraction de tous les incidents TPG associés au numéro ou à la lettre de la ligne demandée.

2. *Agrégation et classement :* Comptabilisation des accidents par nom d'arrêt et tri décroissant pour isoler le Top 3.

3. *Jointure textuelle enrichie :* Chaque arrêt du Top 3 fait l'objet d'une jointure avec arrets.json afin d'ajouter la commune et ses coordonnées GPS (latitude et longitude).

Exemple de résultat pour la ligne 14 :

```
Total collisions pour la ligne 14 : 184
Top 3 des arrêts les plus touchés :
------------------------------------------------------------------
 - Bel-Air            :  24 collisions | GENÈVE (46.2048, 6.1435)
 - Gare Cornavin      :  19 collisions | GENÈVE (46.2102, 6.1425)
 - Palladium          :  11 collisions | GENÈVE (46.2023, 6.1368)
------------------------------------------------------------------
```

4.4. Scénario 4 : Bilan territorial de sécurité par commune

- **Sources croisées :** OTC_ACCIDENTS.geojson (SITG) + arrets.json (JSON) + collisions-tpg-avec-tiers.json (JSON)

- **Objectif et description :** Offre une synthèse multi-échelles à l'échelle d'une commune genevoise. Il confronte l'intensité de la desserte des transports en commun et les collisions TPG associées avec la gravité des accidents de la route répertoriés sur le territoire communal par le SITG.

- **Fonctionnement algorithmique :**

1. *Saisie interactive tolérante :* L'utilisateur saisit le nom de l'arrêt recherché. Le module normalise l'entrée (suppression des accents, tirets, ponctuation et majuscules). Si la correspondance est exacte, l'arrêt est directement sélectionné ; si plusieurs arrêts correspondent, un menu interactif numéroté (1 à 8) s'affiche pour lever l'ambiguïté (avec possibilité d'annuler via la touche Entrée).

2. *Recensement des arrêts :* Filtrage d'arrets.json pour constituer l'ensemble des arrêts implantés sur la commune.

3. *Comptage des collisions TPG :* Croisement avec collisions-tpg-avec-tiers.json pour dénombrer les sinistres survenus sur ces arrêts communaux.

4. *Bilan cantonal SITG :* Extraction des accidents routiers généraux situés dans la commune et ventilation selon la gravité des conséquences (dégâts matériels, blessés légers, blessés graves).

Exemple de synthèse pour la commune de Meyrin :

```
Résultats pour Meyrin :
 - Arrêts TPG             : 42
 - Collisions TPG aux arrêts : 87
 - Accidents généraux (SITG) : 312

Gravité SITG :
 - Dégâts matériels    : 245
 - Blessé léger        : 61
 - Blessé grave        : 6
```

4.5. Scénario 5 : Palmarès des arrêts à risque et risque routier environnant (SITG)

- **Sources croisées :** collisions-tpg-avec-tiers.json (JSON) + arrets.json (JSON) + OTC_ACCIDENTS.geojson (SITG)
- **Objectif et description :** Génère automatiquement le classement des 10 arrêts TPG enregistrant le plus d'incidents sur le réseau et réalise une jointure spatiale dynamique avec le fichier cantonal SITG afin de mesurer la sinistralité routière environnante (< 150 m).
- **Fonctionnement algorithmique :**

1. *Calcul du Top 10 :* Dénombrement et tri décroissant des collisions par arrêt sur l'ensemble de l'historique TPG.
2. *Récupération des positions GPS :* Jointure avec arrets.json pour obtenir la latitude et la longitude de chacun des 10 arrêts.
3. *Analyse spatiale de voisinage :* Pour chaque arrêt du palmarès, le script calcule en temps réel la distance de tous les accidents de circulation du canton (formule d'Haversine) et dénombre ceux situés dans un rayon de 150 mètres.

Exemple de palmarès généré :

```
-------------------------------------------------------------------
Rang  | Arrêt TPG            | Collisions TPG  | SITG (<150m)
-------------------------------------------------------------------
#1    | Bel-Air              | 216             | 111
#2    | Gare Cornavin        | 184             | 142
#3    | Rive                 | 145             | 98
#4    | Plainpalais          | 112             | 74
...
-------------------------------------------------------------------
```

5. Guide d'exécution du service local (*How to use*)

Le service local a été développé sous la forme d'un script en ligne de commande autonome en Python. Il repose exclusivement sur des modules natifs de l'environnement standard Python (json, xml.etree.ElementTree, unicodedata, math), ce qui dispense de l'installation de bibliothèques tierces via pip.

5.1. Organisation des fichiers

Pour assurer le bon chargement des jeux de données, le script main.py et les quatre fichiers sources doivent être placés dans le même dossier de travail :

- main.py : Script exécutable du service local.
- arrets.json : Référentiel des arrêts TPG et coordonnées GPS.
- collisions-tpg-avec-tiers.json : Historique des incidents de la régie TPG.
- OTC_ACCIDENTS.geojson : Base cantonale des accidents de circulation SITG.
- meteo_geneve.xml : Historique météorologique consolidé.

5.2. Lancement du programme

Depuis un terminal positionné dans le répertoire du projet, exécuter la commande suivante :
python3 main.py

Au démarrage, le service valide et charge séquentiellement en mémoire les quatre sources de données :

```
Chargement des fichiers...
 - Chargement des arrêts TPG (arrets.json)...
 - Chargement des collisions TPG (collisions-tpg-avec-tiers.json)...
 - Chargement des accidents généraux (OTC_ACCIDENTS.geojson)...
 - Chargement de la météo (meteo_geneve.xml)...
Tous les fichiers sont chargés.
```

5.3. Navigation et ergonomie

L'utilisateur interagit avec le service via un menu textuel numéroté :

- **Choix 1 à 5 :** Exécution du scénario d'analyse correspondant.
- **Choix 0 :** Sortie propre de l'application.
- **Fonctionnalité d'annulation :** Dans tous les scénarios interactifs (Scénarios 1, 3 et 4), un simple appui sur la touche Entrée sans texte permet d'annuler l'opération et de retourner immédiatement au menu principal, sans provoquer de blocage ou d'arrêt inattendu. Pour le Scénario 1, cette touche d'annulation fonctionne à la fois lors de la saisie initiale du nom de l'arrêt et dans le sous-menu de sélection numéroté (1 à 8).

6. Conclusion générale

Ce travail pratique a permis de concevoir et d'implémenter un service de mashup local opérationnel, capable d'unifier des sources de données publiques hétérogènes tant au niveau de leurs formats techniques (JSON, GeoJSON, XML) que de leurs structures sémantiques.

Le recours à des données ouvertes réelles genevoises et fédérales (TPG, SITG, MétéoSuisse) a mis en évidence les défis concrets de l'intégration de données :

1. **La disparité des formats :** Résolue par la conversion intermédiaire et l'agrégation de séries horaires CSV volumineuses en un document XML structuré et standardisé.

2. **L'harmonisation textuelle :** Palliée par un traitement Unicode robuste (normaliser) pour absorber les écarts de saisie (tirets, accents, majuscules) entre différentes bases administratives.

3. **Le croisement multi-critères :** Réalisé sans dépendance externe lourde grâce à des requêtes temporelles (jointures sur dates calendaires) et des calculs spatiaux trigonométriques (formule d'Haversine pour des périmètres de 150 mètres).

Finalement, les cinq scénarios proposés ne se limitent pas à une juxtaposition de tables : ils apportent une réelle valeur ajoutée analytique. Ils permettent d'observer concrètement l'impact des aléas climatiques sur les transports publics, d'identifier les sections critiques des lignes de bus et de tramways, et de distinguer les incidents purement opérationnels des points noirs routiers globaux du canton de Genève.